CORPORACIÓN UNIFICADA NACIONAL DE EDUCACIÓN SUPERIOR (CUN) · ESPECIALIZACIÓN EN INTELIGENCIA ARTIFICIAL

MODELADO CLÁSICO DE MACHINE LEARNING Y DESPLIEGUE EN STREAMLIT

Predicción del valor de viviendas con el dataset California Housing

Anyela María Torres Sánchez · Brandon Andres Ardila Meta · Edwin Arturo Contreras Padua

Asignatura: Aprendizaje Automático · Docente: Dr. Hamilton Rivera Flor

ACA N° 1
Pilar: Ventas
Sector inmobiliario
Octubre 2026

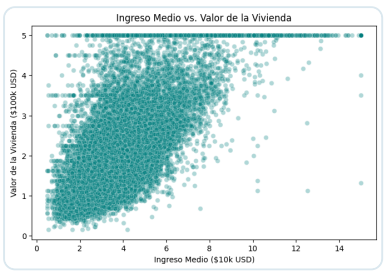
1 CONTEXTO Y SITUACIÓN PROBLEMA

- **Pilar:** Ventas — sector inmobiliario / comercial.
- **Dataset:** California Housing (20.640 registros, 10 variables).
- **Pregunta orientadora:** ¿Cómo transformar datos socioeconómicos y geográficos en una herramienta que estime el precio de una vivienda de forma confiable e interactiva?
- **Objetivo general:** Desarrollar una solución integral de Machine Learning clásico, desde la preparación de datos hasta el despliegue de un tasador interactivo en Streamlit.

IMPACTO Una referencia rápida y accesible para apoyar decisiones de compra y venta de vivienda.

2 DATOS Y PREPARACIÓN

- **EDA:** 20.640 distritos; variable objetivo *median_house_value* (USD).
- **Hallazgo:** relación positiva entre ingreso medio y precio.
- **Nulos:** 207 en *total_bedrooms*; imputación con la mediana.
- **Transformación:** One-Hot Encoding para *ocean_proximity* y estandarización numérica.
- **Partición:** 80% entrenamiento (16.512) y 20% prueba (4.128), semilla 42.



Ingreso medio vs. valor de la vivienda (EDA)

3 RUTA METODOLÓGICA · 5 PASOS

1. **Exploración y EDA**
   Comprensión del problema, distribuciones y valores nulos.
2. **Limpieza y preparación**
   Imputación, One-Hot Encoding, escalado y partición.
3. **Modelado clásico**
   Entrenamiento de Regresión Lineal y Random Forest.
4. **Evaluación**
   R^2, MAE y RMSE sobre el conjunto de prueba.
5. **Despliegue**
   Aplicación interactiva en Streamlit.

20.640	207	16.512	4.128
registros	nulos tratados	entrenamiento	prueba

ALCANCE Y LIMITACIONES

- Los datos son históricos (censo de California, 1990); no reflejan el mercado actual.
- La estimación es una referencia académica y no sustituye un avalúo profesional.
- Trabajo futuro: incorporar datos actuales y más variables del inmueble.

4 MODELOS Y RESULTADOS

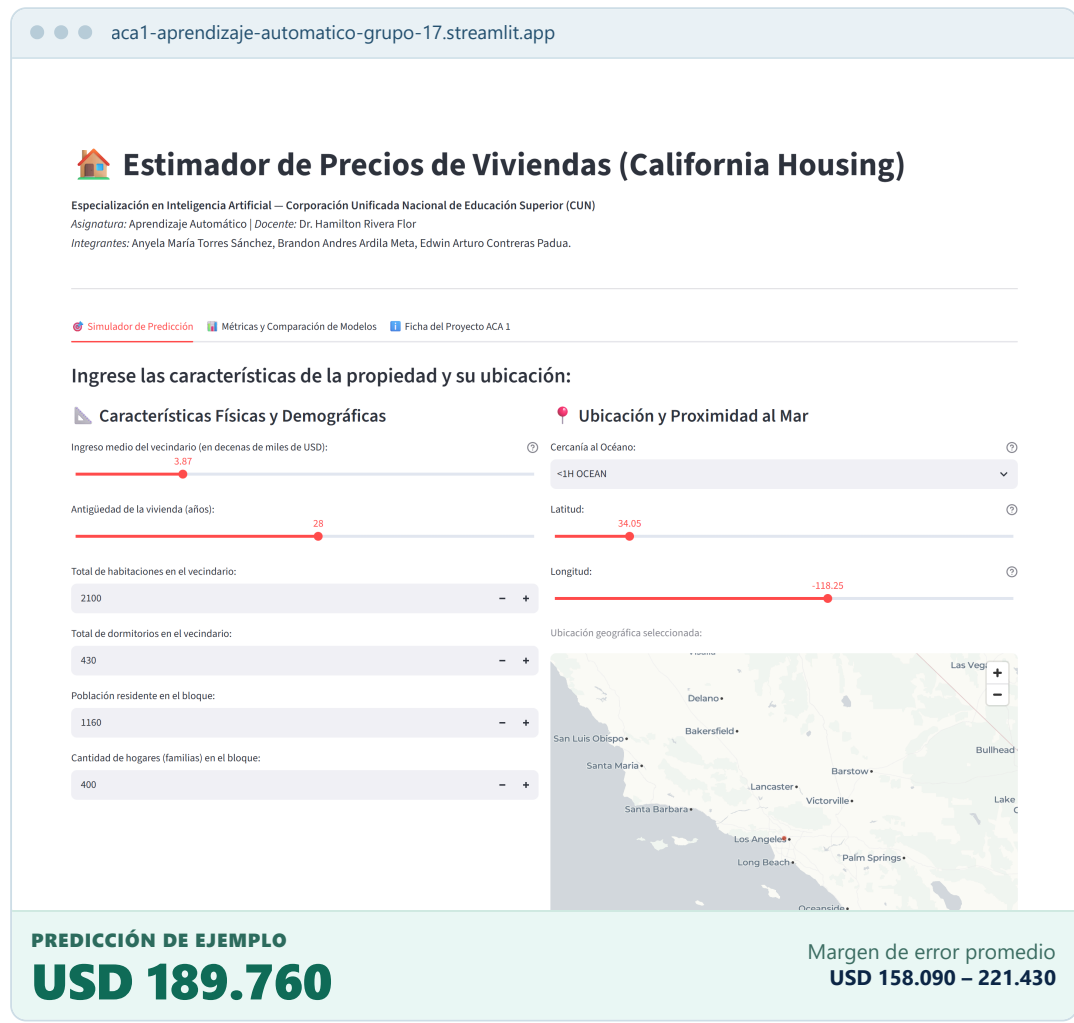
Se compararon dos algoritmos clásicos de aprendizaje supervisado:

1. **Regresión Lineal** — modelo base paramétrico de referencia.
2. **Random Forest Regressor** — ensamble de árboles de decisión.

MÉTRICA	REG. LINEAL	RANDOM FOREST
R^2	62,54 %	**81,67 %**
MAE	USD 50.670	**USD 31.672**
RMSE	USD 70.059	**USD 49.007**

Modelo seleccionado: Random Forest. Redujo el error promedio en ~USD 19.000 y capturó relaciones no lineales entre ubicación, ingreso y precio.

5 VISTA PREVIA DE LA APP EN STREAMLIT



https://aca1-aprendizaje-automatico-grupo-17.streamlit.app/

Datos históricos de California (1990). Referencia académica, no avalúo profesional.

6 CIERRE Y ENLACES

- La preparación de datos fue clave: imputación robusta y transformación de variables.
- Random Forest superó a la Regresión Lineal: R^2 81,67 % y error promedio de USD 31.672.
- La app en Streamlit hace accesible la estimación a usuarios no técnicos; es una referencia, no un avalúo.

Aplicación desplegada
https://aca1-aprendizaje-automatico-grupo-17.streamlit.app/

Repositorio del proyecto
https://github.com/edwincontri/ACA1-Aprendizaje-Automatico

Video de sustentación
https://youtu.be/GRmsT-hqCvA

REFERENCIAS (APA 7)

Géron, A. (2019). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* (2.ª ed.). O'Reilly Media.

Pace, R. K., & Barry, R. (1997). Sparse spatial autoregressions. *Statistics & Probability Letters, 33*(3), 291–297.

Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.