CORPORACIÓN UNIFICADA NACIONAL DE EDUCACIÓN SUPERIOR (CUN)

ESPECIALIZACIÓN EN INTELIGENCIA ARTIFICIAL — ASIGNATURA: APRENDIZAJE AUTOMÁTICO

MODELADO CLÁSICO DE MACHINE LEARNING Y DESPLIEGUE EN STREAMLIT

Autores: Anyela María Torres Sánchez | Brandon Andres Ardila Meta | Edwin Arturo Contreras Padua • Docente: Dr. Hamilton Rivera Flor

1. CONTEXTO Y SITUACIÓN PROBLEMA

- Pilar Temático: Ventas (Sector Inmobiliario / Comercial)
- Dataset: California Housing (20,640 registros, 10 variables)
- Pregunta Orientadora:
  ¿Cómo transformar datos socioeconómicos y geoespaciales en una herramienta analítica clásica que permita predecir el precio comercial de viviendas de manera confiable e interactiva?
- Objetivo General:
  Desarrollar una solución integral de Machine Learning clásico, desde el preprocesamiento de datos hasta el despliegue de un tasador interactivo con Streamlit.

2. CALIDAD Y PREPARACIÓN DE DATOS

- EDA & Hallazgos Iniciales:
  - 20,640 instancias representativas de distritos residenciales.
  - Variable Objetivo: 'median_house_value' (Precio de venta en USD).
  - Fuerte correlación positiva entre ingresos medios y precio.

- Limpieza e Imputación de Faltantes:
  - Se detectaron 207 valores nulos en 'total_bedrooms'.
  - Se aplicó imputación robusta mediante la Mediana.

- Codificación y Transformación:
  - 'ocean_proximity' codificada con One-Hot Encoding.
  - Estandarización numérica con StandardScaler (media=0, std=1).

- Partición de Datos:
  - 80% Entrenamiento (16,512 reg.) | 20% Prueba (4,128 reg.).

3. RUTA METODOLÓGICA (5 PASOS)

Paso 1: EDA	Exploración de variables, nulos y distribuciones
Paso 2: Limpieza	Imputación con mediana, One-Hot y StandardScaler
Paso 3: Modelado	Entrenamiento de Regresión Lineal y Random Forest
Paso 4: Evaluación	Validación con R^2, MAE y RMSE en conjunto test
Paso 5: Despliegue	Interfaz interactiva con simulador en Streamlit

4. MODELOS CLÁSICOS Y MÉTRICAS

Se contrastaron dos algoritmos clásicos de Machine Learning:
1. Regresión Lineal (Modelo base paramétrico de referencia)
2. Random Forest Regressor (Modelo de ensamble de árboles)

Métrica	Reg. Lineal	Random Forest
R^2 (Explicación)	62.54 %	**81.67 % (Ganador)**
MAE (Error Prom.)	$50,670 USD	**$31,672 USD**
RMSE (Error Cuad.)	$70,059 USD	**$49,007 USD**

- Justificación Técnica de Selección:
  Random Forest redujo el error medio (MAE) en ~$19,000 USD y capturó eficientemente las relaciones espaciales complejas y no lineales entre coordenadas, cercanía al mar e ingresos.

5. DESPLIEGUE INTERACTIVO (STREAMLIT)

- Funcionalidades de la Aplicación (app.py):
  - Entrada de Parámetros: Controles deslizantes para ingresos, antigüedad, habitaciones, población y proximidad marítima.
  - Georreferenciación: Mapa interactivo en tiempo real con latitud y longitud del distrito seleccionado.
  - Inferencia Inmediata: Predicción del precio de mercado con rango de tolerancia basado en el MAE (±$31,672 USD).
  - Pestañas Analíticas: Visualización de métricas comparativas y ficha técnica del proyecto.

- Enlaces de Acceso (Entregables Oficiales):
  - Repositorio / Código: github.com/proyecto-cun-aca1
  - Video Sustentación (3 a 5 min): youtu.be/sustentacion-aca1

6. REFERENCIAS BIBLIOGRÁFICAS (APA 7)

- Géron, A. (2019). Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow (2da ed.). O'Reilly Media.
- Pace, R. K., & Barry, R. (1997). Sparse spatial autoregressions. Statistics & Probability Letters, 33(3), 291-297.
- Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825-2830.